

Pronósticos de inflación en Guatemala: ¿Modelos de series de tiempo o algoritmos de *machine learning*?*

Gabriel A. Fuentes[†]

21 de abril, 2022

Resumen

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Quisque nibh ex, mollis nec turpis ac, ultrices mollis quam. Aliquam sed tortor eget dolor dignissim ornare quis in nibh. Duis non nisl convallis, ornare erat et, sagittis mauris. Mauris sit amet sapien vehicula, volutpat mi laoreet, viverra tellus. Aliquam id placerat risus, sed convallis urna. Phasellus varius iaculis tellus ac venenatis. Pellentesque molestie libero orci, in hendrerit dolor semper quis. Nunc sed dolor facilisis, faucibus odio semper, accumsan tellus. Proin pretium felis et urna commodo, in tempor sapien iaculis. Quisque feugiat tincidunt porta. Nulla vestibulum vel nibh non rhoncus. Nunc eu urna velit. In imperdiet magna eget ex auctor, porta aliquam lorem cursus. Nullam et commodo mauris. In ullamcorper egestas erat, quis faucibus lectus. Nullam pellentesque quam eget nibh condimentum, in vestibulum neque posuere. Sed sed lorem vitae lacus laoreet aliquet. Curabitur egestas enim a odio lacinia sodales. Vestibulum fermentum, dui.

Palabras clave: Machine learning, deep learning, series de tiempo, pronósticos, inflación

Clasificación JEL: E31, C22, C45, C53

*Con el propósito de maximizar la reproducibilidad del presente estudio, las bases de datos utilizadas y el código en R se encuentran disponibles en: <https://github.com/gafnts/Inflation-forecasting>

[†]Séptimo semestre, Teoría y Política Monetaria. Correo electrónico: gafnts@gmail.com

1 Introducción

El artículo número tres de la ley orgánica del Banco de Guatemala establece que su objetivo fundamental consiste en propiciar las condiciones monetarias, cambiarias y crediticias que promuevan la estabilidad en el nivel general de precios. En el 2005, como parte de su esfuerzo por lograr este fin, dicha entidad adoptó un régimen de metas explícitas de inflación.

Debido a que naturalmente existe un periodo de tiempo entre el ajuste de las condiciones monetarias por parte del banco central y el efecto que este cambio podría originar en las variables reales del sistema macroeconómico, la autoridad monetaria, bajo un régimen de metas de inflación, actúa en el presente considerando sus pronósticos sobre el comportamiento de los precios en el futuro.

Concretamente, un cambio en la tasa de interés de política monetaria puede demorar entre 12 y 24 meses en ejercer una influencia en la demanda agregada y, por tanto, en tener un impacto en la evolución del ritmo inflacionario interno. En consecuencia, el banco central deberá pronosticar esta variable durante dicho horizonte temporal y efectuar sus decisiones de política monetaria de modo que pueda estar seguro de que los pronósticos y expectativas de inflación se mantendrán dentro de la meta establecida durante el mediano plazo (Moenjak, 2014).

En este sentido, los pronósticos de variables macroeconómicas pueden llevarse a cabo a través de dos enfoques distintos: Métodos estructurales y métodos no estructurales (Diebold, 1998). Los primeros informan a la especificación de sus modelos a través de una teoría económica específica, mientras que los últimos se valen de las correlaciones en forma reducida que subyacen en las series de tiempo, sin depender explícitamente de una teoría económica (Pratap & Sengupta, 2019).

Este estudio en particular se ocupará del segundo enfoque, que al mismo tiempo puede ser subdividido en dos metodologías diferentes. Por un lado se encuentran los métodos econométricos de series de tiempo (que pueden considerarse como modelos relativamente tradicionales) entre los que sobresalen los modelos univariados autorregresivos integrados de medias móviles (ARIMA) y los modelos multivariados de vectores autorregresivos (VAR).

Por el otro, algoritmos de aprendizaje estadístico¹ (*machine learning*) comienzan a ser cada vez más populares, principalmente por la creciente disponibilidad de grandes bases de datos y poder de cómputo, así como un mayor acceso a *software* especializado (Rodríguez-Vargas, 2020), aunque—tal y como mencionan Coulombe, Leroux, Stevanovic, & Surprenant (2020)—los métodos de aprendizaje de máquina en realidad tienen una historia dentro de la literatura macroeconométrica que se remonta hacia inicios de la década de los noventas.

En general, los modelos de series de tiempo asumen que las variables empleadas durante la estimación de los parámetros se vinculan entre sí a través de una dinámica intrínseca regida por relaciones lineales que únicamente conducen a soluciones que oscilan periódicamente o que exhiben un comportamiento exponencial, de modo que la totalidad en la conducta irregular del sistema es atribuida únicamente a una entrada que es tanto externa como estocástica (Kantz & Schreiber, 2004). Sin embargo, esta entrada aleatoria puede no ser la fuente exclusiva de irregularidad. Existe evidencia que tanto series macroeconómicas como datos financieros exhiben interesantes estructuras no-lineales que se originan debido al impacto de perturbaciones en diferentes fases del ciclo económico (LeBaron, 1994).

Pregunta principal de la investigación.

¹A lo largo de la presente investigación los términos “aprendizaje estadístico,” “aprendizaje de máquina” y “aprendizaje automático” serán empleados indistintamente.

Por lo que, dada la naturaleza no-lineal entre la relación entre las variables macroeconómicas y el ritmo inflacionario, ha habido un mayor interés en el uso de modelos no lineales.

Metodología que se utilizará para resolverlo.

La metodología consistirá en una competencia de predicción fuera de muestra (*out-of-sample*) entre una amplia gama de modelos que difieren con respecto a ciertas características esenciales: linealidad o no linealidad, regularización y selección de hiperparámetros.

Algunos de los modelos más populares como redes neuronales artificiales (ANN) y redes neuronales recurrentes (RNN), máquinas de vectores de soporte (SVM), bosques aleatorios (*random forest*) y pronósticos de ensambles entre modelos de series de tiempo y algoritmos de aprendizaje automático.

¿Por qué es importante?

High inflation rates deteriorate economic growth rates, diminish real wages, and increase production costs. Similarly, a low inflationary environment is considered as a negative economic indicator that is associated with decreasing level of the demand in the economy. Therefore, the forecasting of inflation within different time horizons is important. The aim of this study is to compare time series and machine learning models for inflation forecasting in different horizons (Ülke, Sahin, & Subasi, 2018).

Resumen de la composición estructural del documento en cuestión.

2 Revisión de la literatura

3 Metodología

4 Resultados

5 Conclusiones

6 Referencias

- Coulombe, P. G., Leroux, M., Stevanovic, D., & Surprenant, S. (2020). How is machine learning useful for macroeconomic forecasting? *arXiv:2008.12477 [Econ, Stat]*. Retrieved from <http://arxiv.org/abs/2008.12477>
- Diebold, F. X. (1998). The Past, Present, and Future of Macroeconomic Forecasting. *Journal of Economic Perspectives*, 12(2), 175–192. <https://doi.org/10.1257/jep.12.2.175>
- Kantz, H., & Schreiber, T. (2004). *Nonlinear time series analysis* (Vol. 7). Cambridge university press.
- LeBaron, B. (1994). Chaos and nonlinear forecastability in economics and finance. *Philosophical Transactions of the Royal Society of London. Series A: Physical and Engineering Sciences*. <https://doi.org/10.1098/rsta.1994.0099>
- Moenjak, T. (2014). *Central banking: Theory and practice in sustaining monetary and financial stability*. Singapore: John Wiley.
- Pratap, B., & Sengupta, S. (2019). *Macroeconomic Forecasting in India: Does Machine Learning Hold the Key to Better Forecasts?* Rochester, NY. <https://doi.org/10.2139/ssrn.3852945>
- Rodríguez-Vargas, A. (2020). Forecasting Costa Rican inflation with machine learning methods. *Latin American Journal of Central Banking*, 1(1), 100012. <https://doi.org/10.1016/j.latchb.2020.100012>
- Ülke, V., Sahin, A., & Subasi, A. (2018). A comparison of time series and machine learning models for inflation forecasting: empirical evidence from the USA. *Neural Computing and Applications*, 30(5), 1519–1527. <https://doi.org/10.1007/s00521-016-2766-x>